

Python et Open data - 2022/2023

TD4: Restaurants new-yorkais

Ce sujet traite des fichiers JavaScript Object Notation (JSON). Ce format permet de stocker des données structurées, par exemple avec une organisation hiérarchique.

Préambule

- 1. Dans votre dossier PythonOpenData, créez un sous-répertoire TD4 dans lequel vous réaliserez l'ensemble des travaux.
- 2. Lancer l'éditeur Visual Studio Code.
- 3. Dans Visual Studio Code, ouvrir le dossier PythonOpenData/TD4.

Dans ce TD, on se tourne vers un jeu de données recensant des notes attribuées à des restaurants de la ville de New York.

Exercice 1: Chargement des données

- 1. Sur CURSUS, télécharger le jeu de données NYfood.json et l'enregistrer dans le dossier PythonOpen-Data/TD4.
- 2. Visualiser avec Visual Studio Code le contenu du fichier JSON.
- 3. Quels sont les attributs (clés de dictionnaires) de ce jeu de données? Que contient l'attribut grades (qui signifie notes en français)?

Exercice 2: Extraction d'informations élémentaires

Dans la suite de ce sujet, on nomme « restaurant » chaque dictionnaire issu du fichier JSON. Les questions suivantes nécessitent de manipuler les données depuis Python et le code produit devra être inclus dans un nouveau fichier td4.py.

- 1. Charger le contenu du fichier NYfood.json dans une liste de dictionnaires, chaque dictionnaire représentant un restaurant.
- 2. Combien y a-t-il de restaurants dans ce fichier?
- 3. Combien y a-t-il de restaurants situés à Manhattan listés dans ce fichier?
- 4. Écrire une fonction qui prend en entrée la liste des restaurants et retourne une liste sans doublon des quartiers dans lesquels se situent les restaurants listés dans ce fichier.
- 5. Écrire une fonction qui prend en entrée la liste des restaurants et affiche, pour chaque restaurant du quartier "Manhattan", un récapitulatif de la forme nom_du_restaurant: adresse où l'adresse est composée de building, street, zipcode New York, USA
- 6. Quel est le nombre total de notes attribuées aux restaurants du fichier?
- 7. Quelles sont les valeurs possibles de notes attribuées aux restaurants par les évaluateurs?

Exercice 3: Travail spécifique sur les dates

- 1. Remarquer que les dates associées aux notes n'ont pas été reconnues comme telles
- 2. Écrire une fonction qui prend en entrée la liste des restaurants et retourne une version transformée dans laquelle les dates sont codées au format datetime.datetime.
- 3. Calculer, pour chaque mois de l'année 2014, le nombre total de notes attribuées (on rappelle que les variables de type datetime ont des attributs year et month accessibles via d.year et d.month).

Exercice 4: Export au format CSV

Dans cette partie, il va s'agir d'enregistrer un export du contenu du fichier NYfood.json au format CSV, en s'assurant donc que l'on n'ait plus d'attributs imbriqués.

- 1. Écrire une fonction qui prend en entrée le jeu de données précédent et retourne une nouvelle version de ce jeu de données dans lequel l'attribut grades a été supprimé et remplacé par un attribut n_grades qui indique le nombre de notes reçues.
- 2. Écrire une fonction qui prend en entrée le jeu de données précédent et retourne une nouvelle version de ce jeu de données dans lequel l'attribut address est supprimé et remplacé par deux nouveaux attributs latitude et longitude (l'attribut coordinates est une liste contenant la longitude et la latitude, stockées dans cet ordre).
- 3. En utilisant les deux fonctions précédentes, exporter cette nouvelle version du jeu de données dans un fichier nommé NYfood.csv.