Python et Open data - 2023/2024

TD7: Les Cesars 2016 (récupération de données via des requêtes HTTP)

Pour cette séances, vous travaillerez sur les données disponibles à l'adresse suivante :

http://my-json-server.typicode.com/alemaitr/python_opendata_12/cesars2016

Ces données concernent des films récompensés lors de la cérémonie des Césars 2016.

Préambule

- Créer sur votre disque un dossier TD7 dans PythonOpenData.
- Lancer l'éditeur Visual Studio Code.
- Dans Visual Studio Code, ouvrir le dossier PythonOpenData/TD7 et créez un fichier td7.py.

Exercice 1: Un premier coup d'œil aux données

- Q.1.1. À l'aide d'un navigateur web, visualisez les données disponibles à l'URL citée ci-dessus.
- Q.1.2. Quel est le format de ces données?
- Q.1.3. Combien de films sont décrits dans ces données?
- Q.1.4. Dans votre fichier td7.py, récupérez le jeu de données en question et vérifiez que le nombre de films est conforme à ce que vous aviez noté précédemment.

Exercice 2: Les "François" réalisateurs

Q.2.1. Écrivez une fonction qui prend en entrée un jeu de données tel que retourné par l'API qui nous intéresse et retourne la liste des réalisateurs dont le prénom est "François".

Exercice 3: Les biopics

Il est à noter que l'API qui fournit les données peut être interrogée de la façon suivante :

http://my-json-server.typicode.com/alemaitr/python_opendata_12/cesars2016?attribut=valeur auquel cas ne seront retournés que les films pour lesquels le champ attribut vaut valeur.

- Q.3.1. Écrivez une fonction qui prend en entrée un genre cinématographique genre et un nom (de famille) d'acteur/actrice nom_famille et retourne la liste des titres de films du genre donné pour lesquels au moins un acteur ou une actrice a pour nom de famille nom_famille. La requête HTTP devra être incluse dans le corps de la fonction et vous ferez en sorte de minimiser la quantité de données à récupérer par votre script.
- Q.3.2. Affichez la liste des "Biopic" dans lesquels joue une actrice ou un acteur du nom de "de Lencquesaing".
- Q.3.3. Modifiez la fonction précédente pour que si l'argument nom_famille n'est pas fourni lors de l'appel, la fonction retourne l'ensemble des titres de films du genre voulu.
- Q.3.4. Testez la fonction précédente pour afficher la liste des films du genre "Biopic".

Exercice 4: Les actrices et acteurs

- Q.4.1. Écrivez une fonction qui prend en entrée un jeu de données tel que retourné par l'API qui nous intéresse et retourne une liste avec doublons des actrices et acteurs contenus dans le jeu de données.
- Q.4.2. Écrivez une fonction qui prend en entrée un acteur et retourne son nom de famille, s'il existe, ou sinon son surnom. La chaîne de caractères retournée devra être en caractères majuscules.
- Q.4.3. En utilisant les fonctions codées aux deux questions précédentes, écrivez une fonction qui prend en entrée un jeu de données tel que retourné par l'API qui nous intéresse et retourne une liste sans doublon des actrices et acteurs contenus dans le jeu de données, triés dans l'ordre alphabétique des noms de famille (ou surnom si le nom de famille n'est pas spécifié).
- Q.4.4. En utilisant la fonction codée à la question 4.1, écrivez une fonction qui prend en entrée un jeu de données tel que retourné par l'API qui nous intéresse et retourne la liste des acteurs ayant joué dans plusieurs films.

Exercice 5: Pour aller plus loin: export des données au format CSV

On souhaiterait maintenant exporter les données récupérées au format CSV. Malheureusement, le format CSV attend des données sous formes de tableaux, ce qui n'est pas très commode pour stocker des listes d'acteurs par films. La stratégie à suivre pour enregistrer ces données sera donc d'enregistrer 3 fichiers CSV :

- Un premier fichier qui contiendra les informations concernant les films du jeu de données;
- Un deuxième fichier qui contiendra les informations concernant les actrices et acteurs du jeu de données ;
- Un troisième fichier qui listera les associations entre films et actrices/acteurs.
- Q.5.1. Pour permettre de faire les liens souhaités entre films et acteurs, il faut fournir à chaque film un identifiant unique. Note : les acteurs disposent déjà d'un identifiant unique. Écrivez une fonction qui prend en entrée un jeu de données et retourne une nouvelle version de ce jeu de données dans laquelle chaque film a un nouvel attribut id_film unique.
- Q.5.2. Appliquez cette fonction à votre jeu de données.
- Q.5.3. Enregistrez les informations relatives aux acteurs dans un premier fichier acteurs.csv qui contiendra 4 colonnes : id_acteur, prénom, nom, surnom.
- Q.5.4. Écrivez une fonction qui prend en entrée un jeu de données et retourne deux listes : la première correspondant au jeu de données dans lequel on a supprimé toutes les informations concernant les acteurs et la seconde stockant les liens entre acteurs et films sous la forme de paires stockées dans un dictionnaire {"id_film":idf, "id_acteur":ida}.
- Q.5.5. Enregistrez les informations relatives aux films dans un fichier films.csv qui contiendra 7 colonnes : id_film, titre, date_sortie, durée, réalisateur.prénom, réalisateur.nom et genre.
- Q.5.6. Enregistrez les informations permettant de lier les actrices et acteurs aux films dans un fichier liens.csv qui contiendra 2 colonnes : id_film et id_acteur.